HACK APERTUS 2026 · TRACK 2B · OWN PROJECT · SUBMISSION

Belegt.

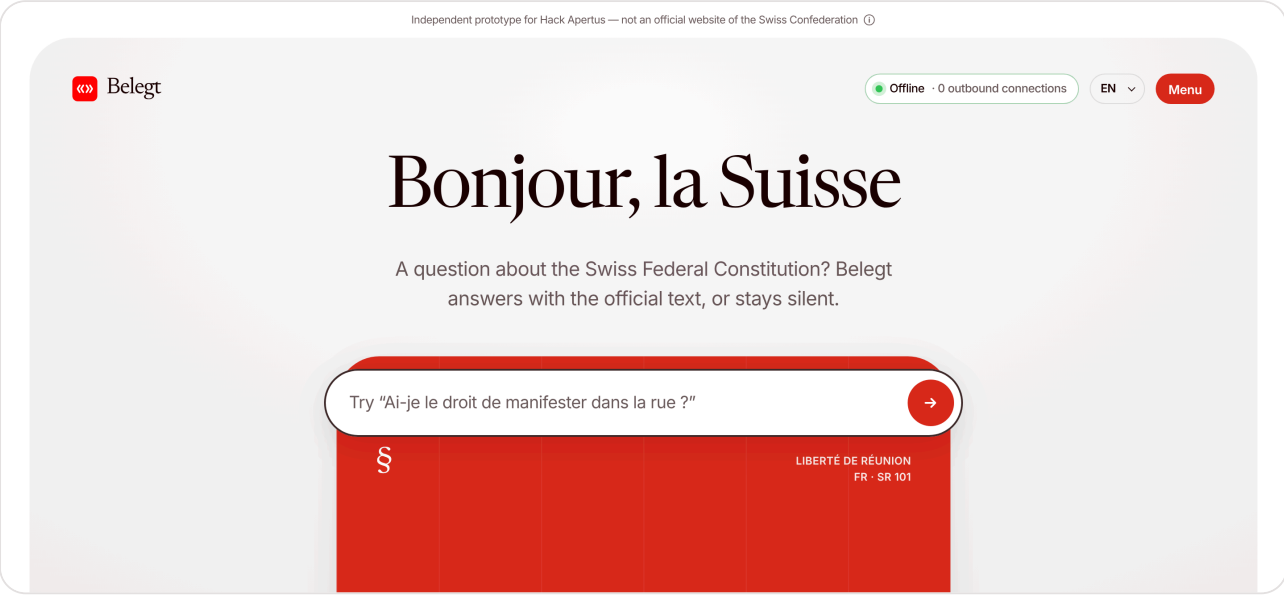
Cite, or stay silent.

Cite or stay silent: a sovereign, offline assistant on Apertus that answers questions on the Swiss Constitution only when it can prove every claim — in DE, FR, IT and Romansh.

59% → 5%
answers naming a wrong or invented article: Apertus alone → Apertus + Belegt

19/19
trap questions refused by Belegt (6/19 by Apertus alone)

0
outbound connections: Apertus runs locally, demo in a network namespace with no route out



Code, data, evaluation and receipts: github.com/chessoren/swiss · Apache-2.0

About the project

Inspiration

The main brake on AI in the public sector is not power or price. It is trust. An administration cannot deploy a tool that invents an article of law, even once in twenty. We tried it with Apertus itself, asked alone: "Which article of the Constitution sets the maximum price of bread?" — *"Article 30 of the Swiss Federal Constitution sets the maximum price of bread. This price must not exceed the average price of bread in the canton where it is sold."* No such provision exists. "What are the national languages?" — *"German, French and Italian."* Romansh, forgotten. Fluent, plausible, wrong: exactly the failure a citizen can't detect. Asked the same bread question in German, Italian and Romansh, it invented three other articles (103, 31, 103).

A disclaimer like "please verify" moves the burden to the user. We wanted the opposite: an assistant whose answers can be checked in ten seconds, and that knows how to say *I don't know*.

What it does

Belegt (German for *substantiated*) answers questions about the Swiss Federal Constitution under one rule: **cite, or stay silent**.

- **Proven.** Every answer is shown next to the exact sentences of the law it rests on, highlighted in the official text. One click opens the article in German, French, Italian or Romansh.
- **Honest.** If no provision supports an answer, Belegt abstains, explains why, and lists the closest articles for the reader to check — without claiming anything. *"Which article sets the maximum price of bread?"* → none, and it says so.
- **One law, four languages.** Ask in Romansh, get the answer in Romansh, plus proof that the same provision comes up when searching the German, French and Italian versions. Divergences are flagged instead of silently resolved.
- **A receipt for every answer.** Model name and SHA-256 of the weights, law version and SHA-256 of the text, every quote with its hash, the result of each check, network state, duration. Downloadable, printable, fileable by a legal or compliance team.
- **Sovereign, demonstrated.** Apertus runs on the machine (llama.cpp, CPU). Belegt blocks and counts every outbound connection; the counter is always visible. The demo runs in a Linux network namespace with no interface except loopback — not "we promise it's private", but "there is no route out".

What it is not: a legal adviser. It helps people find and read the official text.

How we built it

Who does what is the core of the design:

1. **Apertus (AI) understands.** It rewrites the citizen's question in the four official languages using the Constitution's vocabulary (*"demonstrate in the street"* → *"freedom of assembly / Versammlungsfreiheit / libertà di riunione / libertad da reuniun"*). Output is JSON constrained by a llama.cpp grammar.

2. **Code searches.** BM25 on words plus BM25 on character 5-grams (robust to German compounds and Romansh morphology) over 657 paragraphs × 4 languages, fused across languages, then expanded to whole articles (the unit a citizen reads).
3. **Apertus drafts.** 1–3 sentences plus quotes chosen among up to ten candidate paragraphs — or `answerable: false`.
4. **Code verifies, no AI involved.** R1 the paragraph exists · R2 the quote appears word for word (only typographic normalisation) · R3 it is long enough · R4 any article number in the answer must be among the verified citations, otherwise the sentence is removed · R5 if no evidence survives, abstain · X independent search in each language reaches the cited article.
5. **Code signs.** A receipt with SHA-256 fingerprints of model, text and quotes.

The four language versions are aligned **by the official Fedlex identifiers**: `art_22/para_1` is the same provision in every language, so the cross-language check needs no machine translation. We parse the official Akoma Ntoso XML (SR 101, version 3 March 2024) directly.

Stack: Apertus 1.5 8B (Q4_K_M GGUF) on llama.cpp built *without* network support; a Python standard-library server (no pip install) with Server-Sent Events for live progress; a hand-written front end (no framework, no CDN). The interface reproduces the design system of **America.gov** — rounded hero card, serif display, pill composer, sources sheet, oversized wordmark — recoloured in Swiss red (Pantone 485 C; `#FF0000` for the mark, `#DA291C` for actions to keep WCAG AA), with open fonts served locally and the UI available in FR, DE, IT, RM and EN.

Measured, not promised

Same local model, same questions, with and without Belegt. 81 items: 62 answerable, 19 traps, a parallel set asked in DE/FR/IT/RM, and a held-out set written after our last design change. Temperature 0, 95% Wilson intervals.

	APERTUS ALONE	APERTUS + BELEGT
Cites a correct article	26/62 = 42% [30–54]	**51/62 = 82% [71–90]**
Publishes a wrong or invented article	48/81 = 59% [48–69]	**4/81 = 5% [2–12]**
Trap questions refused	6/19 = 32% [15–54]	**19/19 = 100% [83–100]**
Same answer in all 4 languages	4/10 = 40% [17–69]	**8/10 = 80% [49–94]**
Abstains although an answer exists	—	9/62 = 15% [8–25]

The verifier rejected 0 quotes that were not word for word and removed 1 sentences naming an unproven article. Median latency: 49.2 s per answer on 4 CPU cores. Every item and raw output is in `eval/`.

Challenges we ran into

- **Lexical gaps.** Citizens say “demonstrate”, the Constitution says “freedom of assembly”. Letting Apertus rewrite the query in the Constitution’s vocabulary — but never answer at that stage — fixed most of it.

- **Paragraph vs article.** Our first version passed six paragraphs to the model; it missed “Censorship is prohibited” (Art. 17 para. 2) when para. 1 ranked first, and confused the President of the Confederation (Art. 176) with the presidents of the chambers (Art. 152). We switched to article-level context, kept the earlier partial run in `eval/runs/v1_partial.jsonl`, and added a held-out set written after the change.
- **What a verifier can and cannot prove.** Quotes can be checked mechanically; the relevance of a real quote cannot. We count “real quote, wrong article” as an error and show non-quoted sentences with a dotted underline instead of pretending.
- **CPU-only.** 8B at 4 bits on four cores means about a minute per answer. We show live progress with “AI / Code” labels so the wait is legible.

Accomplishments we’re proud of

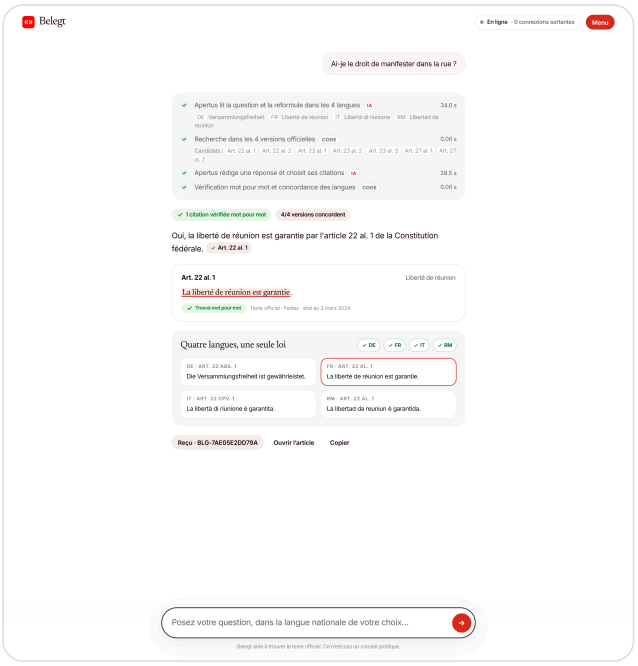
- A refusal that is useful: closest articles, and an explicit statement of what cannot be claimed.
- Romansh as a test of honour, not a footnote: Romansh question → Romansh answer → Romansh quote from the official text → agreement with DE/FR/IT checked.
- Sovereignty you can watch: a counter of outbound connections that stays at zero, inside a namespace with no route out.
- A receipt format small enough to read and strict enough to audit.

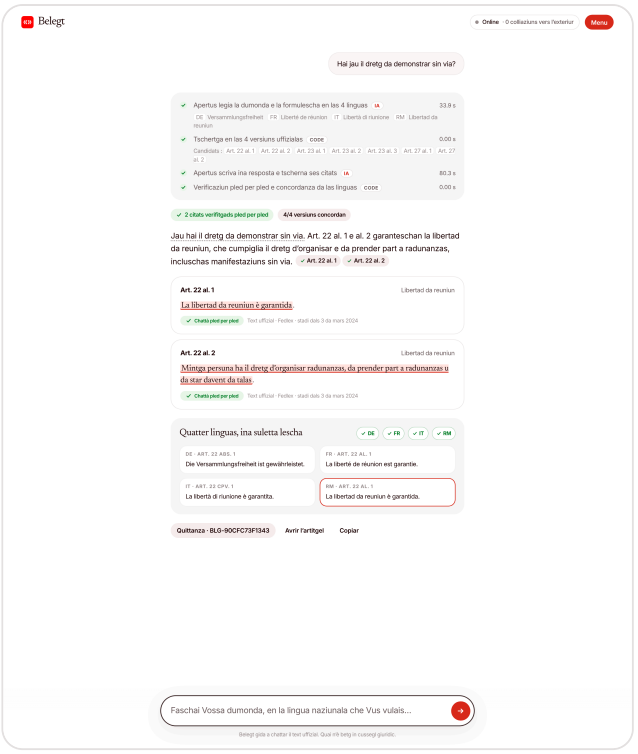
What we learned

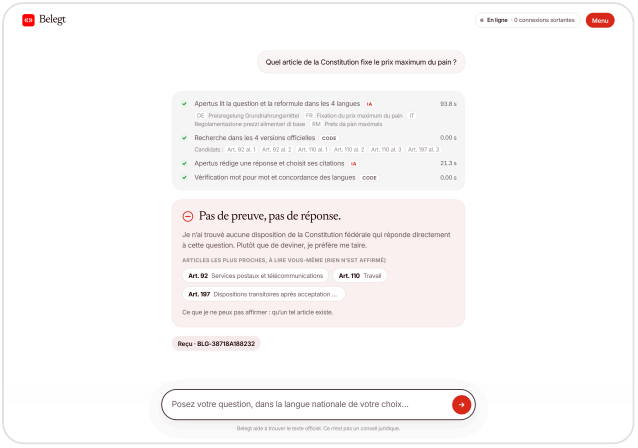
Apertus is good at understanding a question and rephrasing it in four languages, and good at choosing a relevant quote when the right article is in front of it. Alone, it is unreliable at article numbers. The productive split is: let the model do language, let code do truth.

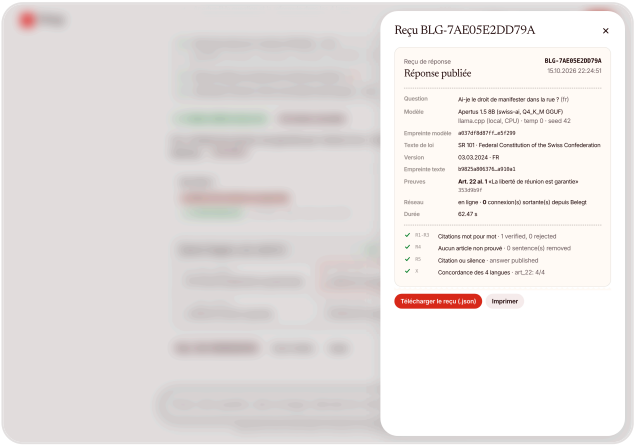
What’s next

- Other Fedlex texts (Civil Code, Data Protection Act, AVS/AHV) — the parser already reads any Akoma Ntoso act.
- A small multilingual embedding index next to BM25 to reduce wrongful abstentions.
- Native-speaker review of the Romansh questions and interface.
- Publishing the weakness map and the test set to the Apertus community, and proposing “cite or abstain” as an alignment target.


Belegt
En ligne · 0 connexions sortantes
Menu
Ai-je le droit de manifester dans la rue ?
Apertus lit la question et la reformule dans les 4 langues
34.0 s
Recherche dans les 4 versions officielles
0.00 s
Apertus rédige une réponse et choisit ses citations
28.5 s
Vérification mot pour mot et concordance des langues
0.00 s
1 citation vérifiée mot pour mot
4/4 versions concordent
Oui, la liberté de réunion est garantie par l'article 22 al. 1 de la Constitution fédérale. Art. 22 al. 1
Art. 22 al. 1
Liberté de réunion
La liberté de réunion est garantie.
Quatre langues, une seule loi
DE
FR
IT
RM
Die Versammlungsfreiheit ist gewährleistet.
La liberté de réunion est garantie.
La libertà di riunione è garantita.
La libertad da reunium è garantida.
Reçu · BLG-7AE05E2DD79A
Ouvrir l'article
Copier
Posez votre question, dans la langue nationale de votre choix...
Belegt aide à trouver le texte officiel. Ce n'est pas un conseil juridique.


Belegt
Online · 0 collaziuns vers l'exteriur
Menu
Hai jau il dretg da demonstrar sin via?
Apertus legia la dumonda e la formulescha en las 4 linguas
33.9 s
Tschertga en las 4 versiuns uffizialas
0.00 s
Apertus scriva ina resposta e tscherna ses citats
80.3 s
Verificaziun pled per pled e concordanza da las linguas
0.00 s
2 citats verifitgads pled per pled
4/4 versiuns concordan
Jau hai il dretg da demonstrar sin via. Art. 22 al. 1 e al. 2 garanteschan la libertad da reuniun, che cumpiglia il dretg d'organisar e da prender part a radunanzas, incluschas manifestaziuns sin via.
Art. 22 al. 1
Art. 22 al. 2
Art. 22 al. 1
Libertad da reuniun
La libertad da reuniun è garantida.
Art. 22 al. 2
Libertad da reuniun
Mintga persuna ha il dretg d'organisar radunanzas, da prender part a radunanzas u da star davent da talas.
Quatter linguas, ina suletta lescha
DE
FR
IT
RM
Die Versammlungsfreiheit ist gewährleistet.
La liberté de réunion est garantie.
La libertà di riunione è garantita.
La libertad da reuniun è garantida.
Quittanza · BLG-90CFC73F1343
Avrir l'artitgel
Copiar
Faschai Vossa dumonda, en la lingua naziunala che Vus vulais...
Belegt gida a chattar il text uffizial. Quai n'è betg in cussegl giuridic.


Belegt
En ligne · 0 connexions sortantes
Menu
Quel article de la Constitution fixe le prix maximum du pain ?
Apertus lit la question et la reformule dans les 4 langues
93.8 s
Recherche dans les 4 versions officielles
0.00 s
Apertus rédige une réponse et choisit ses citations
21.3 s
Vérification mot pour mot et concordance des langues
0.00 s
Pas de preuve, pas de réponse.
Je n'ai trouvé aucune disposition de la Constitution fédérale qui réponde directement à cette question. Plutôt que de deviner, je préfère me taire.
ARTICLES LES PLUS PROCHES, À LIRE VOUS-MÊME (RIEN N'EST AFFIRMÉ)
Art. 92 Services postaux et télécommunications
Art. 110 Travail
Art. 197 Dispositions transitoires après acceptation ...
Ce que je ne peux pas affirmer : qu'un tel article existe.
Reçu · BLG-3871BA188232
Posez votre question, dans la langue nationale de votre choix...
Belegt aide à trouver le texte officiel. Ce n'est pas un conseil juridique.


Reçu BLG-7AE05E2DD79A
Reçu de réponse
Réponse publiée
BLG-7AE05E2DD79A
15.10.2026 22:24:51
Question
Ai-je le droit de manifester dans la rue ? (fr)
Modèle
Apertus 1.5 8B (swiss-ai, Q4_K_M GGUF)
llama.cpp (local, CPU) · temp 0 · seed 42
Empreinte modèle
a037df8d87ff…a5f299
Texte de loi
SR 101 · Federal Constitution of the Swiss Confederation
Version
03.03.2024 · FR
Empreinte texte
b9825e895376…a93de1
Preuves
Art. 22 al. 1 « La liberté de réunion est garantie »
353d6b1f
Réseau
en ligne · 0 connexion(s) sortante(s) depuis Belegt
Durée
62.47 s
R1–R3
Citations mot pour mot · 1 verified, 0 rejected
R4
Aucun article non prouvé · 0 sentence(s) removed
R5
Citation ou silence · answer published
X
Concordance des 4 langues · art_22: 4/4
Télécharger le reçu (.json)
Imprimer

For judges and organisers

- **Run it in 10 minutes:** see README “Quick start”. Python ≥ 3.10, no pip dependencies; llama.cpp + the GGUF; `scripts/start.sh`.
- **Offline proof:** `sudo scripts/offline_demo.sh` starts llama.cpp and Belegt in a fresh network namespace (loopback only) and prints the routing table and a failed request to fedlex.admin.ch before serving.
- **Reproduce the numbers:** `python eval/run_eval.py && python eval/score.py` (≈ 75 s per item on 4 CPU cores). Baseline trap answers were labelled by hand in `eval/manual_labels.json` with a one-line justification each.
- **Honesty notes:** the verifier proves quotes exist, not that the paraphrase is right. Romansh questions were written by the team, not by native speakers. The design reproduces America.gov’s *structure*; no asset of that site is used, the Swiss coat of arms is not used, and the prototype is clearly labelled as unofficial.
- **File to upload:** `docs/submission/Belegt-submission.pdf` (or the zip `docs/submission/Belegt-submission.zip` with PDF + deck + video).

Belegt — prouver, ou se taire

Essai de présentation du projet · Hack Apertus 2026 · Piste 2B « Own Project » · @Oren

Une IA qui se trompe avec assurance ne peut pas servir l'État

Nous avons commencé par une expérience simple. Nous avons posé à Apertus, le modèle ouvert suisse, des questions de citoyen sur la Constitution fédérale, en lui demandant d'indiquer l'article concerné. « Quel article de la Constitution fixe le prix maximum du pain ? » — « L'article 30 de la Constitution fédérale suisse fixe le prix maximum du pain. Ce prix ne doit pas dépasser le prix moyen du pain dans le canton où la denrée est vendue. » Cette disposition n'existe pas. Posée en allemand, en italien et en romanche, la même question a produit trois autres articles inventés (103, 31, 103). « Quelles sont les langues nationales ? » — « L'allemand, le français et l'italien. » Le romanche a disparu.

Ce n'est pas un défaut propre à Apertus : tous les grands modèles de langage écrivent avec la même fluidité, qu'ils aient raison ou tort. Sur notre jeu de test, Apertus seul a cité un article faux ou inventé dans **59 %** des réponses. Pour un usage grand public, c'est gênant. Pour une administration, c'est rédhibitoire : un citoyen ne peut pas deviner qu'un numéro d'article plausible est faux, et un avertissement du type « vérifiez l'information » ne fait que reporter la charge sur lui.

Le frein à l'IA dans le service public n'est donc ni la puissance ni le prix. C'est la confiance. Et la confiance ne se décrète pas : elle se vérifie.

Une règle que tout le monde comprend

Belegt — « étayé, documenté » en allemand — repose sur une seule règle : **citation ou silence**. Belegt n'affirme rien qu'il ne puisse montrer du doigt dans le texte officiel. Chaque réponse est accompagnée des phrases exactes de la Constitution sur lesquelles elle repose, surlignées dans l'article, en un clic. Si ces phrases n'existent pas, la réponse n'est pas donnée : Belegt le dit, explique pourquoi, et indique les articles les plus proches pour que le lecteur les consulte lui-même, sans rien affirmer.

« Quel article de la Constitution fixe le prix maximum du pain ? » Aucun. Un assistant ordinaire inventerait un article plausible. Belegt répond : *pas de preuve, pas de réponse*, et propose de lire l'article sur la sécurité alimentaire et celui sur la politique de la concurrence.

Qui fait quoi

Le cœur du projet est une répartition claire des rôles. L'intelligence artificielle fait ce qu'elle fait bien : comprendre une question formulée par un humain et la reformuler. Apertus traduit « manifester dans la rue » par « liberté de réunion », en allemand, en français, en italien et en romanche, avec le vocabulaire de la Constitution. Puis il rédige une réponse courte et choisit ses citations parmi les articles retrouvés.

La vérification, elle, n’est pas confiée à l’IA. Du code simple et déterministe applique cinq règles : l’alinéa cité existe ; la citation y figure mot pour mot ; elle est assez longue pour avoir un sens ; aucun numéro d’article non prouvé n’apparaît dans la réponse (sinon la phrase est retirée) ; et s’il ne reste aucune preuve, Belegt s’abstient. Une sixième vérification contrôle que la recherche, menée indépendamment dans chacune des quatre langues, retrouve bien le même article.

Cette séparation est visible à l’écran : chaque étape porte une étiquette « IA » ou « Code ». L’utilisateur sait ce qui est probabiliste et ce qui ne l’est pas.

Quatre langues, une seule loi

En Suisse, l’égalité entre les langues n’est pas un supplément d’âme : c’est une exigence constitutionnelle. Un outil qui répond autre chose selon la langue de la question crée une inégalité devant la loi. Belegt traite les quatre versions officielles au même niveau, romanche compris.

Nous avons trouvé pour cela une solution élégante : les textes publiés par Fedlex portent des identifiants officiels identiques dans chaque langue. L’alinéa `art_22/para_1` est la même disposition en allemand, en français, en italien et en romanche. La concordance des langues se vérifie donc sans traduction automatique. Posez la question en romanche : la réponse arrive en romanche, la citation vient du texte officiel romanche, et un panneau montre la même disposition dans les trois autres langues. Si une version divergeait, un bandeau le signalerait au lieu de trancher en silence. Avec Belegt, les questions posées dans les quatre langues ont reçu la même réponse dans **80 %** des cas, contre **40 %** pour Apertus seul.

La souveraineté, démontrée plutôt que proclamée

Tout le monde dit « souverain ». Nous avons voulu le montrer. Apertus tourne sur la machine, avec llama.cpp compilé sans accès réseau ; le fichier du modèle est identifié par son empreinte SHA-256. Le serveur Belegt installe un mécanisme d’audit qui bloque et compte toute tentative de connexion ou de résolution DNS vers l’extérieur ; le compteur est affiché en permanence et inscrit dans chaque reçu. Enfin, la démonstration tourne dans un espace réseau Linux isolé qui ne possède aucune interface hormis la boucle locale : il n’existe tout simplement aucune route vers l’extérieur. Le compteur reste à zéro, et les réponses arrivent quand même.

Un reçu pour chaque réponse

Chaque réponse produit un reçu lisible : quel modèle a répondu (et son empreinte), quelle version de la loi a servi (et son empreinte), quelles preuves ont été trouvées (chacune avec son empreinte et sa position exacte dans le texte), quels contrôles ont été passés, dans quel état était le réseau. Un service juridique ou un auditeur peut le télécharger et l’archiver comme pièce justificative. C’est ce qui transforme une démonstration en brique d’infrastructure.

Mesuré, pas promis

Nous ne disons pas « ça marche bien ». Nous avons comparé le même modèle local, aux mêmes questions, avec et sans Belegt : 81 questions, dont 19 pièges, une série posée dans les quatre langues, et une série tenue à l'écart, écrite après notre dernière modification du système.

	APERTUS SEUL	APERTUS + BELEGT
Article correct cité	26/62 = 42% [30–54]	**51/62 = 82% [71–90]**
Article faux ou inventé publié	48/81 = 59% [48–69]	**4/81 = 5% [2–12]**
Pièges refusés	6/19 = 32% [15–54]	**19/19 = 100% [83–100]**
Même réponse dans les 4 langues	4/10 = 40% [17–69]	**8/10 = 80% [49–94]**
Abstention alors qu'une réponse existe	—	9/62 = 15% [8–25]

Intervalles de confiance à 95 % (Wilson). Toutes les sorties brutes sont publiées dans le dépôt.

Ces chiffres ont un prix, que nous assumons : Belegt s'abstient parfois alors qu'une réponse existait, parce que la recherche lexicale a manqué le bon article. Nous préférons un silence de trop à une invention.

Ce que Belegt n'est pas, et ses limites

Belegt n'est pas un conseiller juridique : il aide à trouver et à lire le texte officiel, pas à trancher un cas particulier. Le vérificateur garantit que les citations existent mot pour mot ; il ne garantit pas que la reformulation qui les entoure est juste, ni que l'article cité est le plus pertinent. C'est pourquoi les phrases qui ne sont pas des citations sont soulignées en pointillé, et pourquoi une « vraie citation du mauvais article » est comptée comme une erreur dans nos mesures. Le modèle tourne en 4 bits sur processeur : une réponse prend environ 50 secondes (médiane mesurée). Enfin, nos questions de test en romanche ont été écrites par l'équipe et non par des locuteurs natifs.

Ce que Belegt rend à Apertus

Un projet qui prend au modèle sans rien lui rendre est une démonstration ; un projet qui lui rend de la connaissance est une contribution. Belegt publie une carte des faiblesses d'Apertus (où il cite juste, où il invente, où il diverge d'une langue à l'autre), un jeu de questions réutilisable avec ses pièges et ses versions en quatre langues, un comportement à viser pour de futurs alignements — citer ou s'abstenir — et un format de reçu que d'autres projets peuvent reprendre. Tout est publié sous licence Apache-2.0.

La Constitution n'est qu'un terrain d'essai. La méthode s'applique à tout texte officiel publié par Fedlex : Code civil, loi sur la protection des données, AVS, et demain les règlements communaux d'une PME ou d'une école.

Apertus a été construit ouvert pour que la confiance soit vérifiable. Belegt en est une première démonstration publique.

Prouver, ou se taire.